

# Image Classification

이미지 분류

# Deep Residual Learning For Image Recognition(ResNet)


-10 Dec 2015, CVPR

- 목적: 깊은 네트워크를 쉽게 훈련시키기 위해 Residual Learning 개념 도입
- 결론: ResNet을 사용하면 최적화가 쉽고, 깊은 층에서 이전 모델에 비해 좋은 성능 보임

단순히 층을 깊게 쌓았더니 오히려 training error가 높아지는 degradation 문제가 발생  
-> 이 문제를 해결하기 위해 Residual Learning 제안


## <Residual Learning>

- 가정: residual mapping이 쉽다. Identity mapping이 optimal이다.  $F(x)$
- $H(x)$  전체를 학습시키는 것이 아닌  $H(x)-x$ , 즉  $F(x)$ 를 학습
- Shortcut connection을 이용하여 identity mapping 진행
- $y = F(x, \{W_i\}) + W_s x$
- $X$ 의 차원 확장에 zero padding 또는 linear projection 사용



## <Experiments>

- Plain net: degradation 문제 발생 = 깊은 모델의 성능이 저하
- ResNet: 깊은 모델이 더 좋은 성능을 보임, 수렴속도 빠름
- Bottleneck 구조: 1x1 convolution layer는 차원 확장, 축소에 사용



# Image Generation

이미지 생성

# Generative Adversarial Nets(GAN)

-10 Jun 2014, NIPS

- 목적: Generative 모델 G와 Discriminative 모델 D를 동시에 훈련시켜 데이터 생성
- 결론: 다른 모델에 비해 낫다고 할 수는 없지만 잠재력을 입증

G는 실제 데이터의 분포를 포착하고, D는 실제 데이터와 생성 데이터를 판별

$$\rightarrow \min_G \max_D V(G, D) = \mathbb{E}_{x \sim p_{data}(x)} [\log D(x)] + \mathbb{E}_{z \sim p_z(z)} [\log(1 - D(G(z)))]$$


<Optimal D>

- $\mathbb{E}_{x \sim p_{data}(x)} [\log D(x)] + \mathbb{E}_{z \sim p_z(z)} [\log(1 - D(G(z)))]$   
 $= \int p_{data}(x) \log D(x) dx + p_g(x) \log(1 - D(x)) dx$
- 미분 = 0이 되게 하는  $D^* = \frac{p_{data}(x)}{p_{data}(x) + p_g(x)}$  (이때  $D = 1/2$ )

<Optimal G>

- $\mathbb{E}_{x \sim p_{data}} [\log D^*(x)] + \mathbb{E}_{x \sim p_g} [\log(1 - D^*(x))]$   
 $= -\log 4 + KL\left(p_{data} \middle| \frac{p_{data} + p_g}{2}\right) + KL\left(p_g \middle| \frac{p_{data} + p_g}{2}\right)$   
 $= -\log 4 + 2 * JSD(p_{data} | p_g)$
- JSD는 0 이상의 양수, 즉  $p_{data} = p_g$  일 때 최소값  $-\log 4$ 를 가짐

GAN's training(D->G)



# 논문의 제목은 24

-논문 등재 날짜와 등재지는 12

- Abstract에 나온 목적과 결론

<키워드>

- 설명
- 설명

# 논문의 제목은 24

-논문 등재 날짜와 등재지는 12

- Abstract에 나온 목적과 결론

<키워드>

- 설명
- 설명